گزارش کپشنر وابسته به سؤال: وابستگی به سؤال در برابر تصویر (kaggle_mini)

چک‌پوینت	`outputs/kaggle_mini/best.pt` : مدل `MMTransformerCopyCaptioner` ، بهترین CIDEr-D اعتبارسنجی در اِپاک ۱۷
تقسیم داده‌ها	`configs/kaggle_mini.yaml` ، ردیف‌های بدون اشتراک تصویر از `vqa_v2_question_dependent_captions_train2014.json` : **train** ردیف ۰ تا ۹۵۰۰ (۹,۵۰۲ نمونه / ۲,۸۹۵ تصویر)، **val** ردیف ۹۵۰۰ تا ۱۰۰۰۰ (۵۰۴ / ۱۴۶)، **test** ردیف ۱۰۰۰۰ تا ۱۰۵۰۰ (۴۹۴ / ۱۶۵). فقط train برای آموزش استفاده شده است
رمزگشایی	beam 3، جریمهٔ طول ۰٫۷، بدون تکرار ۳-گرم (همانند `benchmark.py`)
اسکریپت	`scripts/captioner_probe.py` (بخش ۸). همهٔ کپشن‌های همهٔ حالت‌ها در `outputs/probe/kaggle_mini_{split}.json` ذخیره شده‌اند

فهرست: ۱ معیارها · ۲ نتایج اصلی · ۳ یک تصویر، سؤال‌های مختلف · ۴ یک سؤال، تصویرهای مختلف · ۵ فقط سؤال · ۶ فقط تصویر · ۷ جمع‌بندی · ۸ بازتولید

۱. معیارها

نوع سؤال (از روی پاسخ و قانون QD):

نوع	تعریف	train / val / test
yes/no	پاسخ «yes» یا «no» است	2,741 / 143 / 134
number	پاسخ عددی، یا قانون `how_many`	1,747 / 99 / 92
color	قانون `what_color` یا «what color...»	1,564 / 80 / 73
other	بقیه (اشیا، مکان‌ها، ورزش‌ها، کنش‌ها، ...)	3,450 / 182 / 195

معیار	روی	تعریف
BLEU-1 / BLEU-4، CIDEr-D، ROUGE-L	همه	در مقایسه با تنها کپشن مرجع QD. این معیارها بیشتر **شکل جمله** را می‌سنجند
AnswerHit	غیر yes/no	همهٔ کلمه‌های پاسخ در کپشن آمده باشند (اعداد نرمال می‌شوند: «no/none» = 0، «two» = 2)
PolarityAcc	yes/no	کپشن دقیقاً وقتی منفی است (no, not, n't, nothing, none, nobody, never، ...) که پاسخ «no» باشد
CountAcc	number	اولین عدد کپشن برابر پاسخ باشد
سازگاری پاسخ (AC)	همه	کپشن با پاسخ انسانی سازگار است: برای yes/no همان PolarityAcc، برای number همان CountAcc، و در غیر این صورت AnswerHit. این عدد خلاصهٔ این پرسش است که «آیا پاسخ را می‌توان فقط از روی کپشن خواند؟»
سهم کلمه‌های سؤال	همه	سهم کلمه‌هایی از کپشن که در سؤال هم آمده‌اند
کپشن پیش‌فرض (fallback)	همه	سهم کپشن‌هایی که دقیقاً برابر کپشن حفظشدهٔ `"a tree is in front of the giraffes"` هستند

نقاط مرجع: ۴۷ تا ۴۹ درصد پاسخ‌های yes/no «yes» هستند، پس همیشه «no» گفتن PolarityAcc برابر ۰٫۵۱ (train) / ۰٫۵۲ (test) / ۰٫۵۳ (val) می‌دهد. ردیف **prior** در جدول‌ها یک خط پایهٔ فقط-سؤال بدون مدل است: پرتکرارترین پاسخ train برای (نوع سؤال، دو کلمهٔ اول سؤال).

۲. نتایج اصلی: همهٔ حالت‌ها

حالت‌ها (همان چک‌پوینت، همان نمونه‌ها):

حالت	تصویر	سؤال	بخش
normal	واقعی	واقعی	مرجع
shuffle	تصویر دیگری از همان تقسیم	واقعی	بخش ۴: یک سؤال، تصویر متفاوت
mean	میانگین ویژگی‌های ناحیه‌ای کل تقسیم («تصویر میانگین»)	واقعی	بخش ۵: فقط سؤال
mask	هیچ (همهٔ ناحیه‌ها پوشانده شده‌اند)	واقعی	بخش ۵: فقط سؤال
noq	واقعی	خالی (`[BOS, EOS]`)	بخش ۶: فقط تصویر
prior	–	دو کلمهٔ اول + نوع	بخش ۵: خط پایه بدون مدل

۲٫۱ کلی

تقسیم	حالت	CIDEr-D	BLEU-1	BLEU-4	ROUGE-L	AnswerHit	PolarityAcc	CountAcc	AC	تغییر نسبت به normal
train	**normal**	**5.45**	**0.763**	**0.572**	**0.749**	**0.357**	**0.598**	**0.295**	**0.427**	**–**
	shuffle	4.62	0.723	0.507	0.705	0.159	0.574	0.241	0.279	54.6%
	mean	4.65	0.717	0.502	0.704	0.178	0.583	0.249	0.295	50.3%
	mask	4.17	0.634	0.401	0.682	0.190	0.557	0.219	0.296	66.5%
	noq	0.30	0.242	0.037	0.211	0.050	0.488	0.005	0.175	97.5%
	prior	–	–	–	–	0.178	0.550	0.249	0.285	–
val	**normal**	**4.41**	**0.689**	**0.455**	**0.671**	**0.230**	**0.587**	**0.313**	**0.331**	**–**
	shuffle	4.11	0.678	0.432	0.652	0.147	0.552	0.273	0.262	59.5%
	mean	4.15	0.682	0.431	0.657	0.172	0.538	0.323	0.276	51.6%
	mask	3.67	0.594	0.347	0.626	0.139	0.566	0.232	0.258	69.4%
	noq	0.26	0.225	0.028	0.203	0.036	0.510	0.000	0.161	96.4%
	prior	–	–	–	–	0.141	0.531	0.333	0.252	–
test	**normal**	**4.90**	**0.739**	**0.516**	**0.718**	**0.281**	**0.582**	**0.293**	**0.362**	**–**
	shuffle	4.26	0.696	0.459	0.672	0.125	0.507	0.250	0.229	55.5%
	mean	4.44	0.703	0.472	0.684	0.158	0.507	0.272	0.253	52.4%
	mask	3.85	0.594	0.349	0.646	0.139	0.545	0.228	0.249	67.8%
	noq	0.34	0.248	0.042	0.219	0.058	0.470	0.000	0.170	97.6%
	prior	–	–	–	–	0.169	0.507	0.304	0.261	–

۲٫۲ سازگاری پاسخ به تفکیک نوع سؤال

تقسیم	نوع (n)	normal	shuffle	mean	mask	noq	prior
train	(2,741) yes/no	**0.598**	0.574	0.583	0.557	0.488	0.550
	(1,747) number	**0.294**	0.240	0.249	0.219	0.005	0.249
	(1,564) color	**0.377**	0.230	0.280	0.324	0.000	0.183

	(3,450) other	**0.379**	0.086	0.095	0.114	0.091	0.139
val	(143) yes/no	**0.587**	0.552	0.538	0.566	0.510	0.531
	(99) number	0.313	0.273	0.323	0.232	0.000	**0.333**
	(80) color	0.212	0.175	**0.263**	0.237	0.000	0.113
	(182) other	**0.192**	0.066	0.049	0.038	0.044	0.049
test	(134) yes/no	**0.582**	0.507	0.507	0.545	0.470	0.507
	(92) number	0.293	0.250	0.272	0.228	0.000	**0.304**
	(73) color	0.247	0.178	**0.260**	**0.260**	0.000	0.205
	(195) other	**0.287**	0.046	0.067	0.051	0.108	0.092

(برای yes/no، PolarityAcc = AC؛ برای number، CountAcc = AC؛ برای color/other، AnswerHit = AC.) CIDEr-D کپشن‌های normal به تفکیک نوع در other ۴٫۵۹، color ۶٫۵۶، number ۳٫۹۵، yes/no ۵٫۲۵. test: رنگی: بهترین مقدار هر ردیف.

۳. یک تصویر، سؤال‌های مختلف

همهٔ جفت‌های سؤال‌های متفاوتی که دربارهٔ یک تصویر پرسیده شده‌اند (رمزگشایی normal). «نوع متفاوت» یعنی مثلاً یک سؤال رنگ در برابر یک سؤال شمارش روی یک تصویر.

	train	val	test
تصویرهای دارای حداقل ۲ سؤال	2,344	119	131
جفت سؤال (همه / نوع متفاوت / نوع یکسان)	25,364 / 17,721 / 7,643	1,491 / 1,013 / 478	1,000 / 695 / 305
کپشن متفاوت است: نوع متفاوت	**99.8%**	**99.8%**	**99.7%**
کپشن متفاوت است: نوع یکسان	98.7%	99.2%	97.7%
هم‌ترازی با سؤال: نوع متفاوت	**95.5%**	**95.7%**	**96.0%**
هم‌ترازی با سؤال: نوع یکسان	92.6%	91.2%	90.2%
پاسخ خودِ سؤال در کپشن (نوع متفاوت، غیر yes/no)	33.4%	19.2%	24.8%
پاسخ سؤال دیگر در کپشن (نوع متفاوت)	2.7%	2.0%	1.4%
پاسخ خود / پاسخ دیگری (نوع یکسان)	31.3% / 12.4%	18.0% / 12.0%	22.5% / 13.6%
هر دو کپشنِ جفت با پاسخ خود سازگارند (AC)	19.7%	9.9%	13.4%

هم‌ترازی با سؤال = کپشنِ سؤال *i* (با F1 کیسهٔ کلمات) به مرجعِ *i* نزدیک‌تر است تا به مرجعِ سؤال دیگر *j* روی همان تصویر (تساوی = ½). مقدار تصادفی = ٪۵۰.

نمونه‌ها (test، هر بلوک یک تصویر):

تصویر	نوع	سؤال	پاسخ	کپشن
23096	number	How many cars are there?	2	there are two cars ✓
	yes/no	Is the parking meter gray?	yes	the parking meter is gray ✓
	yes/no	Is it raining?	no	it is not raining ✓
	yes/no	Is there a red car in this picture?	no	there is no red car in the picture ✓
	other	What is on the pole?	parking meter	a car is on the pole ✗

23098	other	What type of sport are they playing?	tennis	they are playing tennis ✓
	other	What is the woman doing?	playing tennis	the woman is playing tennis ✓
	yes/no	IS this person serving the ball?	no	the person is not serving the ball ✓
	other	What is the little girl wearing on her head?	hat	the little girl is wearing a ball ✗
	number	How many hands is on the racket?	2	there is one person ✗
23047	color	What color is the blender?	white	the blender is blue ✗
	color	What color is the lit up light?	white	the lit up is red ✗
	number	How many blue cakes are visible?	0	two blue cakes are visible ✗
	yes/no	Is the child eating yogurt?	yes	the child is not eating eating ✗
	other	Where is the watermelon?	bowl	a tree is in front of the giraffes ✗ (fallback)
22954	color	What color is the tile on the wall?	white	the tile on the wall is white ✓
	number	How many pots are shown?	3	two pots are shown ✗
	other	What is hanging on the back of the stove?	oven mitts	a <unk> is hanging on the back of the stove ✗
	yes/no	Is there more than one metal pan?	yes	a tree is in front of the giraffes ✗ (fallback)

نتیجه: کپشنر به‌شدت به سؤال وابسته است. سؤال‌های مختلف روی یک تصویر تقریباً همیشه کپشن‌های متفاوت می‌دهند (۹۹٫۷ تا ۹۹٫۸ درصد برای نوع‌های متفاوت). ۹۶٪ کپشن‌ها به مرجعِ سؤال خودشان نزدیک‌ترند تا به مرجعِ سؤال دیگر. پاسخ تقریباً هیچ‌وقت از یک سؤال به سؤال دیگر نشت نمی‌کند (۱٫۴ تا ۲٫۷ درصد برای نوع‌های متفاوت). شکل جمله همیشه با سؤال جور است؛ درست بودن جای پاسخ موضوع جداگانه‌ای است (بخش‌های ۴ و ۵).

۴. یک سؤال، تصویرهای مختلف

۴٫۱ جابه‌جایی تصویر (shuffle): همهٔ نمونه‌ها، سؤال ثابت، تصویر عوض می‌شود

	train	val	test
کپشن تغییر کرد	54.6%	59.5%	55.5%
پاسخِ استخراج‌شده تغییر کرد (قطبیت / شمارش / کپشن)	50.2%	53.2%	51.0%
AC: normal → shuffle	**0.427 → 0.279**	**0.331 → 0.262**	**0.362 → 0.229**
AnswerHit	0.357 → 0.159	0.230 → 0.147	0.281 → 0.125
PolarityAcc	0.598 → 0.574	0.587 → 0.552	0.582 → 0.507
CountAcc	0.295 → 0.241	0.313 → 0.273	0.293 → 0.250
CIDEr-D	5.45 → 4.62	4.41 → 4.11	4.90 → 4.26
سهم کلمه‌های سؤال (shuffle / normal / مرجع)	0.72 / 0.71 / 0.46	0.70 / 0.70 / 0.44	0.71 / 0.70 / 0.46

به تفکیک نوع (بخش ۲٫۲): **other** با تصویر دیگر فرو می‌ریزد (test از ۰٫۲۸۷ به ۰٫۰۴۶)، در حالی که **color** (۰٫۲۴۷ ← ۰٫۱۷۸)، **number** (۰٫۲۹۳ ← ۰٫۲۵۰) و **yes/no** (۰٫۵۸۲ ← ۰٫۵۰۷) خیلی کمتر تغییر می‌کنند.

نمونه‌ها (test؛ یک سؤال، تصویر واقعی در برابر تصویر جابه‌جاشده):

سؤال	پاسخ	تصویر واقعی	تصویر دیگر
What room is this?	kitchen	this is the kitchen ✓	this is a frisbee
What sport is being played?	tennis	tennis is being played ✓	a fork is being played
What sport is the woman playing?	tennis	the woman is playing tennis ✓	the woman is playing <unk>
What color are the dogs?	brown	the dogs are brown ✓	the dogs are blue
What color is the tile on the wall?	white	the tile on the wall is white ✓	the tile on the wall is brown
How many dogs are in the picture?	2	there are two dogs ✓	there are two dogs (بدون تغییر)
How many boats are in the picture?	1	there are two boats ✗	there are two boats (بدون تغییر)
Is it sunny?	no	it is not sunny ✓	it is not sunny (بدون تغییر)

۴٫۲ جفت‌های طبیعی: متن یکسان سؤال روی تصویرهای مختلف

	train	val	test
گروه‌های سؤال (حداقل ۲ تصویر) / نمونه‌ها	927 / 3,498	21 / 50	25 / 56
جفت‌هایی با پاسخ انسانی **متفاوت**	9,297	28	29
← کپشن تغییر کرد	58.6%	75.0%	69.0%
← پاسخِ استخراج‌شده تغییر کرد	58.7%	67.9%	69.0%
← هر دو کپشن سازگار	21.0%	14.3%	31.0%
جفت‌هایی با پاسخ انسانی **یکسان**	2,880	13	9
← کپشن یکسان	84.6%	69.2%	88.9%
← هر دو کپشن سازگار	65.9%	53.8%	33.3%

val و test فقط ۲۶ تا ۲۹ جفت با پاسخ متفاوت دارند، پس نرخ‌های آن‌ها تقریبی است. train حدود ۹ هزار جفت دارد.

نمونه‌ها (test؛ هر خانه یک تصویر متفاوت):

سؤال	پاسخ‌ها	کپشن‌ها
What type of animal is this?	bird / zebra / cow	"this is a bird" / "this is a zebra" / "this is a cow" ✓✓✓
What is the man holding?	frisbee / dog	"…holding a frisbee" / "…holding a dog" ✓✓
What is the child holding?	tennis racket / umbrella	"…a tennis racket" / "…an umbrella" ✓✓
What sport is being played?	tennis / baseball / frisbee	"tennis…" / "baseball…" / "tennis…" ✓✓✗
How many people are present?	2 / 15	"two people are present" ×2 ✓✗

What color is the sky?	gray ×3 / blue	"the sky is blue" ×4 ✗✗✗✓
Is it raining?	yes / no	"it is not raining" ×2 ✗✓
What color is the bus?	yellow and green / yellow	"the bus is red" ×2 ✗✗

نتیجه: کپشن برای حدود نیمی از نمونه‌ها از تصویر پیروی می‌کند. برای اشیا، حیوانات، ورزش‌ها و کنش‌ها، کلمهٔ پاسخ از تصویر می‌آید. برای شمارش، رنگ و yes/no عمدتاً نه.

۵. فقط سؤال (تصویر حذف شده)

دو راه برای حذف تصویر: **mask** (بدون ناحیه) و **mean** (میانگین ناحیه‌ای تقسیم). **prior** یک حدس فقط-سؤال بدون مدل است.

	train	val	test
AC: normal / mask / mean / prior	**0.427 / 0.296 / 0.295 / 0.285**	**0.331 / 0.258 / 0.276 / 0.252**	**0.362 / 0.249 / 0.253 / 0.261**
CIDEr-D: normal / mask / mean	5.45 / 4.17 / 4.65	4.41 / 3.67 / 4.15	4.90 / 3.85 / 4.44
BLEU-4: normal / mask / mean	0.572 / 0.401 / 0.502	0.455 / 0.347 / 0.431	0.516 / 0.349 / 0.472
کپشن عیناً برابر حالت (mask) normal	33.5%	30.6%	32.2%

به تفکیک نوع در test (normal ← mask ← prior): yes/no ۰٫۵۸۲ ← ۰٫۵۴۵ ← ۰٫۵۰۷، number ۰٫۲۹۳ ← ۰٫۲۲۸ ← **۰٫۳۰۴**، other ۰٫۲۸۷ ← ۰٫۰۵۱ ← ۰٫۰۹۲، color ۰٫۲۴۷ ← **۰٫۲۶۰** ← ۰٫۲۰۵.

نمونه‌ها (test):

سؤال	پاسخ	با تصویر	فقط سؤال (mask)
What color is the tile on the wall?	white	the tile on the wall is white	the tile on the wall is white
How many pots are shown?	3	two pots are shown	two pots are shown
Is anyone riding a bicycle?	yes	no one is riding a bicycle	no one is riding a bicycle
What type of sport are they playing?	tennis	they are playing tennis	they they are playing baseball
What room is this?	kitchen	this is the kitchen	this is the bathroom bathroom
What is this person riding on?	dirt bike	this person is riding a motorcycle	this person is riding a hat
What is the woman doing?	playing tennis	the woman is playing tennis	the woman is walking walking

آنچه این بخش نشان می‌دهد:

1. **مدل بدون تصویر هم جملهٔ درست را برای سؤال می‌نویسد** (CIDEr-D در test ۳٫۸۵ در برابر ۴٫۹۰؛ یک‌سوم کپشن‌ها عیناً یکسان‌اند). روانی جمله کم می‌شود (`"they they are playing"`، `"front front front"`)، چون دیکودر هرگز بدون ناحیه‌ها آموزش ندیده است.
2. **شمارش و رنگ از روی سؤال پاسخ داده می‌شوند.** در val و test، دقت فقط-سؤال برای number و color به خوبیِ حالت با تصویر است (number: prior ۰٫۳۰۴ ≥ normal ۰٫۲۹۳؛ color: mask ۰٫۲۶۰ ≥ normal ۰٫۲۴۷). فقط روی تصویرهای *آموزشی*

تصویر برای رنگ کمک می‌کند (۰٫۳۷۷ در برابر ۰٫۳۲۴) که نشانهٔ حفظ کردن است.

3. **yes/no نزدیک به پیش‌فرضِ سؤال است.** PolarityAcc با تصویر ۰٫۵۸ تا ۰٫۶۰، بدون تصویر ۰٫۵۵ تا ۰٫۵۷، و همیشه-«no» ۰٫۵۱ تا ۰٫۵۳.

4. **سؤال‌های other به تصویر نیاز دارند.** بدون تصویر AC از ۰٫۲۸۷ به ۰٫۰۵۱ می‌افتد (test)، حتی پایین‌تر از prior (۰٫۰۹۲).

۶. فقط تصویر (سؤال حذف شده)

«فقط کپشن» در اینجا به معنای خروجیِ **فقط-تصویر** کپشنر در نظر گرفته شده است: تصویر واقعی با سؤال خالی (`[BOS, EOS]`). مدل هرگز بدون سؤال آموزش ندیده است. این که آیا *پاسخ* را می‌توان فقط از روی کپشن خواند، همان چیزی است که AC در بخش‌های ۲ تا ۵ می‌سنجد.

	train	val	test
کپشن پیش‌فرض `"a tree is in front of the giraffes"`	**59.4%**	**55.8%**	**66.4%**
کپشن‌های متمایز / نمونه‌ها	1.7%	7.5%	8.5%
AC / AnswerHit / PolarityAcc / CountAcc	0.175 / 0.050 / 0.488 / 0.005	0.161 / 0.036 / 0.510 / 0.000	0.170 / 0.058 / 0.470 / 0.000
در برابر مرجع‌های QD: CIDEr-D / BLEU-4	0.30 / 0.037	0.26 / 0.028	0.34 / 0.042
در برابر **کپشن‌های انسانی COCO**: CIDEr-D، فقط-تصویر / normal	0.107 / 0.222	0.106 / 0.229	0.107 / 0.209
در برابر کپشن‌های انسانی COCO: BLEU-1، فقط-تصویر / normal	0.377 / 0.261	0.333 / 0.247	0.381 / 0.262
کپشن‌های غیر پیش‌فرض که شیئی از کپشن‌های COCO همان تصویر را نام می‌برند (در برابر تصویر دیگر)	63.7% (5.9%)	59.6% (3.8%)	59.3% (3.7%)

نمونه‌ها (test؛ کپشن فقط-تصویر در برابر اولین کپشن انسانی COCO):

تصویر	فقط تصویر	کپشن انسانی COCO
22928	`a dog is shown`	`two tan colored dogs sitting face to face`
22974	`a sandwich is present`	`… a man about to bite into a sandwich`
23047	`a kitchen is present`	`a young boy eating at a counter with a blender …`
23050	`the man is skateboarding`	`a man on a skateboard at the top of a ramp`
22964	`a tennis tennis is shown`	`a woman standing on a tennis court holding a racquet`
22953	`no one is present`	`a kitchen with people eating food …`
22924 / 22926 / 22940 / …	`a tree is in front of the giraffes`	(تصویر زرافه نیستند)

آنچه این بخش نشان می‌دهد:

1. **کپشنر بدون سؤال نمی‌تواند کپشن بنویسد.** برای ۵۶ تا ۶۶ درصد تصویرها یک کپشن حفظ‌شده از داده‌های آموزشی تولید می‌کند. این یک مدل وابسته به سؤال است، نه یک کپشنر عمومی.
2. **وقتی چیز دیگری می‌نویسد، تصویر واقعی را توصیف می‌کند.** ۵۹ تا ۶۴ درصد این کپشن‌ها شیئی از کپشن‌های COCO همان تصویر را نام می‌برند، در برابر ۴ تا ۶ درصد برای یک تصویر تصادفی (`"a dog is shown"`، `"the man is skateboarding"`). ویژگی‌های بصری شیء اصلی را در خود دارند و سؤال است که جمله‌ای دربارهٔ آن را فعال می‌کند.
3. در برابر کپشن‌های انسانی COCO، CIDEr-D در هر دو حالت پایین است (حدود ۰٫۱ تا ۰٫۲). کپشن‌های QD جمله‌های کوتاه و هم‌شکل با سؤال هستند، نه توصیف کامل صحنه؛ پس این مقایسه فقط تأیید می‌کند که خروجیِ فقط-تصویر یک کپشن عمومیِ قابل استفاده نیست.

۷. جمع‌بندی

وابستگی	داوری	شواهد
به سؤال	**قوی**	۹۹٫۸٪ کپشن متفاوت برای سؤال‌های نوع متفاوت روی یک تصویر؛ ۹۶٪ هم‌ترازی با سؤال؛ ۱٫۴ تا ۲٫۷ درصد نشت پاسخ بین سؤال‌ها؛ بدون سؤال ۵۶ تا ۶۶ درصد کپشن پیش‌فرض
به تصویر: اشیا، مکان‌ها، ورزش‌ها، حیوانات، کنش‌ها (other)	**وابسته به تصویر (grounded)**	AC در test از ۰٫۲۸۷ به ۰٫۰۴۶ با تصویر دیگر و ۰٫۰۵۱ بدون تصویر؛ جفت‌های هم‌سؤال از تصویر پیروی می‌کنند (bird / zebra / cow)
به تصویر: رنگ	ضعیف / پیش‌فرض	تصویرهای دیده‌نشده: فقط-سؤال (۰٫۲۶۰) ≥ با تصویر (۰٫۲۴۷)؛ `"the sky is blue"` برای آسمان خاکستری. فقط روی تصویرهای آموزشی کمک می‌کند (حفظ کردن)
به تصویر: شمارش	**کور**	CountAcc تقریباً برابر prior (۰٫۲۹۳ test در برابر ۰٫۳۰۴)؛ «two» بدون توجه به تصویر
به تصویر: yes/no	عمدتاً پیش‌فرض	PolarityAcc ۰٫۵۸ تا ۰٫۶۰ در برابر ۰٫۵۱ تا ۰٫۵۵ بدون تصویر
تعمیم‌پذیری	فاصلهٔ متوسط	AC ۰٫۳۶۲ test ← ۰٫۴۲۷ train؛ AnswerHit ۰٫۳۵۷ ← ۰٫۲۸۱

1. **کپشنر سؤال‌محور است، تا حدی به تصویر وابسته است و کورِ بصری نیست.** سؤال جمله را تعیین می‌کند (۷۱٪ کلمه‌های کپشن از سؤال می‌آیند؛ در مرجع‌ها ۴۶٪). تصویر فقط برای سؤال‌های شیء/صحنه جای پاسخ را پر می‌کند.
2. **CIDEr و BLEU وابستگی به تصویر را بیش از واقع نشان می‌دهند.** بدون تصویر هم بالا می‌مانند (CIDEr-D در test ۳٫۸۵ در برابر ۴٫۹۰)، چون شکل جمله از سؤال می‌آید. برای این مدل باید AnswerHit، PolarityAcc، CountAcc و AC گزارش شوند.
3. **ضعیف‌ترین بخش‌ها به ترتیب:** شمارش (کور)، yes/no (نزدیک به پیش‌فرض)، رنگ (پیش‌فرض روی تصویرهای دیده‌نشده)، و برگشت به کپشن حفظ‌شده وقتی مدل مطمئن نیست (۲٫۶ تا ۳٫۲ درصد کپشن‌های normal و ۵۶ تا ۶۶ درصد بدون سؤال).
4. **قدم‌های بعدی** (هم‌راستا با بخش ۵ از `EVAL_V1_VS_V2.md`): اول دادهٔ آموزشی بیشتر. سپس ویژگی‌های بصری بهتر برای شمارش و رنگ (هندسهٔ جعبه‌ها، ویژگی‌های bottom-up از Visual Genome یا یک ویژگی سراسری CLIP)، و یک تابع زیان کمکی برای قطبیت/شمارش روی انکودر. برای سنجش پیشرفت از جدول AC به تفکیک نوع (بخش ۲٫۲) و فاصلهٔ فقط-سؤال (بخش ۵) استفاده کنید.

۸. بازتولید

```
cd QuestionDependentImageCaptioner
python scripts/captioner_probe.py --config configs/kaggle_mini_local.yaml --ckpt outputs/kaggle_mini/bes
t.pt \
  --split test --out outputs/probe/kaggle_mini_test.json       # also --split val / --split train (~15 m
in)
```

`configs/kaggle_mini_local.yaml` همان بازه‌های تقسیم `configs/kaggle_mini.yaml` را با مسیرهای محلی و کش ناحیه‌ای محلی دارد. فایل JSON خروجی شامل همهٔ معیارها (`results.<condition>.<type>`)، تحلیل جفت‌ها (`results.same_image`، `results.same_question`)، مقایسه با COCO (`results.coco_reference`) و همهٔ کپشن‌های همهٔ حالت‌ها (`items`) است. اعداد shuffle/mean/mask با `outputs/ablation/kaggle_mini_ep17_*.json` (`scripts/image_ablation.py`) یکسان‌اند.